

用户数据采集与关联分析

(结课作业)



吴志祥

18205185639

1030624832@qq.com

01 文本数据分析



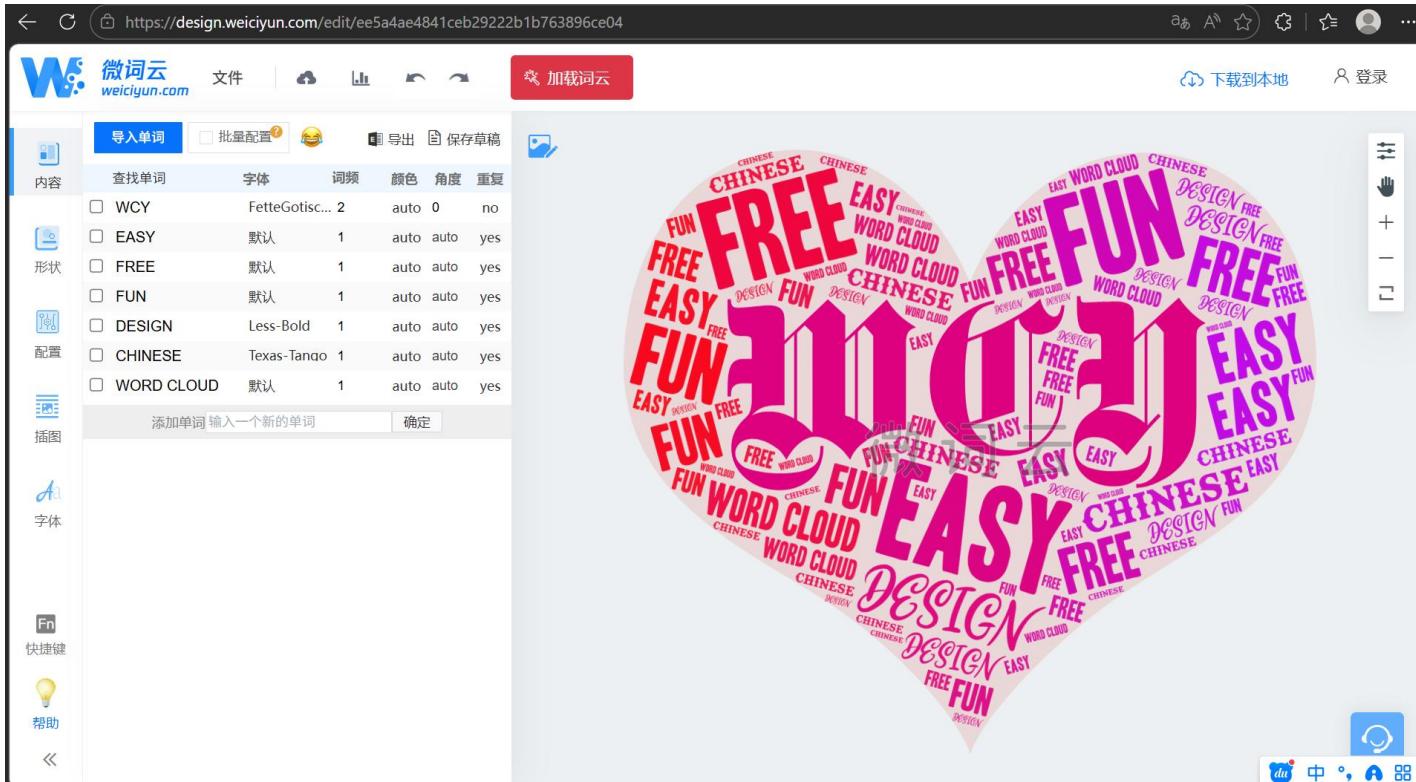
吴志祥

18205185639

cnwzx2012@njtech.edu.cn

第一讲 课程导言与分词

1. 学习使用在线NLPIR分词系统或微词云分词或清华大学分词演示系统（案例演示截图）；



第一讲 课程导言与分词

2. 安装python (anaconda) (编写输出“Hello World. Hello ‘你的姓名’”);



The image shows a screenshot of a Jupyter Notebook interface. A single code cell is visible, containing the following Python code:

```
In [1]: print(f"Hello World. Hello 'wjc'")
```

The output of the code is displayed below the cell, showing the string "Hello World. Hello 'wjc'".

第一讲 课程导言与分词

3. 完成课后作业（001-004，4份代码的运行）。

1. 基本分词

```
In [7]: import jieba
```

```
In [8]: seg_list1 = jieba.cut("曾经有一份真诚的爱情摆在我的面前，我没有珍惜，等到失去的时候才追悔莫及，人世间最痛苦的事情莫过于此。如果上天能够给我一个◀ ➡")
```

```
In [9]: print(''.join(seg_list1))
```

曾经\$有\$一份\$真诚\$的\$爱情\$摆\$我\$的\$面前\$，\$我\$没\$珍惜\$，\$等\$失去\$的\$时候\$才\$追悔莫及\$，\$人世间\$最\$痛苦\$的\$事情\$莫\$于\$此\$。\$如\$上\$天\$能\$给\$我\$一\$重\$新\$来\$过\$的机会\$，\$我\$会\$对\$那\$个\$女\$孩\$子\$说\$三\$个\$字\$：\$‘\$我\$爱\$你\$’\$。\$如\$果\$非\$要\$给\$这\$份\$爱\$加\$上\$一\$个\$期\$限\$，\$我\$希\$望\$是\$，\$一\$万\$年\$

```
In [10]: seg_list2 = jieba.cut("LSTM (Long Short-Term Memory) 是长短期记忆网络，是一种时间递归神经网络，适合于处理和预测时间序列中间隔和延迟相对较长的重要")
```

```
In [11]: print(''.join(seg_list2))
```

LSTM@ (@Long@ @Short@-@Term@ @Memory@) @是@长短期@记忆@网络@， @是@一种@时间@递归@神经网络@， @适合@于@处理@和@预测@时间@序列@中@间隔@和@延迟@相对@较长@的@重要@事件@。

第一讲 课程导言与分词

3. 完成课后作业（001-004，4份代码的运行）。

2.加入词典，是针对第二个片段的，希望是能够完整把“长短期记忆网络”这个术语整体分割出来

```
In [12]: jieba.load_userdict('dict.txt')
```

```
In [13]: seg_list_dict = jieba.cut("LSTM (Long Short-Term Memory) 是长短期记忆网络，是一种时间递归神经网络，适合于处理和预测时间序列中间隔和延迟相对较长")
```

```
In [14]: print('/'.join(seg_list_dict))
```

LSTM/ (/Long/ /Short/-/Term/ /Memory/) /是/长短期记忆网络/， /是/一种/时间递归神经网络/， /适合/于/处理/和/预测/时间/序列/中/间隔/和/延迟/相
对/较长/的/重要/事件/。

第一讲 课程导言与分词

3. 完成课后作业（001-004，4份代码的运行）。

3.加入停用词，针对第一个片段，希望的结果是，结果中不会出现“的、是”等虚词

```
In [15]: stopwords = [line.strip() for line in open('stop_words.txt', 'r', encoding='utf-8').readlines()]
```

```
In [16]: seg_list_stopw = jieba.cut("曾经有一份真诚的爱情摆在我的面前，我没有珍惜，等到失去的时候才追悔莫及，人世间最痛苦的事情莫过于此。如果上天能够给")
```

```
In [17]: final = ''
```

```
In [18]: #这是一行注释，进行分词结果的过滤
for seg in seg_list_stopw:
    if seg not in stopwords:
        final += seg + '/' #叠加，累加
```

```
In [19]: print(final)
```

曾经/有一份/真诚/爱情/摆在/我/面前/我/没有/珍惜/等到/失去/时候/才/追悔莫及/人世间/最/痛苦/事情/莫过于此/如果/上天/能够/给/我/一个/重新/来/过/机会/我会/对/那个/女孩子/说/三个/字/: / ‘我爱你/’ /如果/非要/给/这份/爱/加上/一个/期限/我/希望/一万年/

第一讲 课程导言与分词

3. 完成课后作业（001-004，4份代码的运行）。

现在，可以开启你的小组项目的第一个小小任务啦！就是对一小段有关“功勋科学家”的文本进行分词处理。

The screenshot shows a Jupyter Notebook interface with Python code. The code imports jieba, performs a segmentation on a string containing information about Huang Xuhua, and prints the result. It then adds a user dictionary and stopwords, and prints the final segmented text again. The notebook also includes a section for discussing the meaning of the assignment.

```
# 用单句
seg_list_huang = jieba.cut('黄旭华, 1926年3月12日出生于广东省汕尾市, 毕业于上海交通大学。1949年毕业于上海交通大学。1949年毕业后, 在中国科学院近代物理研究所工作。1958年, 他被调到中国工程物理研究院工作。1964年, 他主持设计了我国第一艘核潜艇。1970年, 他主持设计的核潜艇成功下水。1974年, 他主持设计的核潜艇正式服役。1984年, 他被授予全国劳动模范称号。1999年, 他被授予“两弹一星”功勋奖章。2019年, 他被授予“共和国勋章”。') print('/'.join(seg_list_huang))

# 加入用户词典
jieba.load_userdict('dict.txt')

seg_list_huang = jieba.cut('黄旭华, 1926年3月12日出生于广东省汕尾市, 毕业于上海交通大学。1949年毕业于上海交通大学。1949年毕业后, 在中国科学院近代物理研究所工作。1958年, 他被调到中国工程物理研究院工作。1964年, 他主持设计了我国第一艘核潜艇。1970年, 他主持设计的核潜艇成功下水。1974年, 他主持设计的核潜艇正式服役。1984年, 他被授予全国劳动模范称号。1999年, 他被授予“两弹一星”功勋奖章。2019年, 他被授予“共和国勋章”。') print('/'.join(seg_list_huang))

# 加入词典之后, 哪些词汇被分出来了呢?

# 使用停用词表
stopwords = [line.strip() for line in open('stop_words.txt', 'r', encoding='utf-8').readlines()]

stopwords = open('stop_words.txt', 'r', encoding='utf-8').read()
stopwords = stopwords.split('\n')

stopwords
['的', '了', '是', '啊', '、', '。', '。', '停用']

seg_list_huang = jieba.cut('黄旭华, 1926年3月12日出生于广东省汕尾市, 毕业于上海交通大学。1949年毕业于上海交通大学。1949年毕业后, 在中国科学院近代物理研究所工作。1958年, 他被调到中国工程物理研究院工作。1964年, 他主持设计了我国第一艘核潜艇。1970年, 他主持设计的核潜艇成功下水。1974年, 他主持设计的核潜艇正式服役。1984年, 他被授予全国劳动模范称号。1999年, 他被授予“两弹一星”功勋奖章。2019年, 他被授予“共和国勋章”。') final = '' for seg in seg_list_huang: if seg not in stopwords: final+= seg+'

print(final)

作业的意义:
    • 你可以处理比较复杂的文本啦
    • 你开始尝试接触和理解, 一些具有文化内涵的科技文献资源
```

第一讲 课程导言与分词

3. 完成课后作业（001-004，4

现在，可以开启你的小组项目的一个小小任务啦！就是对一小段有关“功勋科学家”的文本进行分词处理。

```
In [18]: # 简单分词
In [19]: import jieba
In [20]: seg_list_huang = jieba.cut('黄旭华, 1926年3月12日出生于广东省汕尾市, 原籍广东省揭阳市。1949年毕业于上海交通大学。历任北京海军核潜艇研究室副总工')
In [21]: print(''.join(seg_list_huang))
黄旭华/, /1926/年/3/月/12/日出/生于/广/东省/汕尾市/, /原籍/广/东省/揭阳市/. /1949/年/毕业/于/上海交通大学/. /历任/北京/海军/核潜艇/研究室/副/总工程师/、/中船重工集团公司/核潜艇/总体/研究/设计所/研究员/、/名誉/所长/. /1994/年/当选/为/中国工程院院士/。
In [22]: # 加入用户词典
In [23]: jieba.load_userdict('dict.txt')
In [24]: seg_list_huang = jieba.cut('黄旭华, 1926年3月12日出生于广东省汕尾市, 原籍广东省揭阳市。1949年毕业于上海交通大学。历任北京海军核潜艇研究室副总工')
In [25]: print(''.join(seg_list_huang))
黄旭华/, /1926/年/3/月/12/日出/生于/广/东省/汕尾市/, /原籍/广/东省/揭阳市/. /1949/年/毕业/于/上海交通大学/. /历任/北京/海军/核潜艇/研究室/副/总工程师/、/中船重工集团公司/核潜艇/总体/研究/设计所/研究员/、/名誉/所长/. /1994/年/当选/为/中国工程院院士/。
In [26]: # 加入词典之后, 哪些词汇被分出来了呢?
In [27]: # 使用停用词表
In [28]: # stopwords = [line.strip() for line in open('stop_words.txt', 'r', encoding='utf-8').readlines()]
In [29]: stopwords = open('stop_words.txt', 'r', encoding='utf-8').read()
stopwords = stopwords.split('\n')
In [30]: stopwords
Out[30]: ['的', '了', '是', '啊', '、', '、', '。', '，', '停用']
In [31]: seg_list_huang = jieba.cut('黄旭华, 1926年3月12日出生于广东省汕尾市, 原籍广东省揭阳市。1949年毕业于上海交通大学。历任北京海军核潜艇研究室副总工')
In [32]: final =
In [33]: for seg in seg_list_huang:
    if seg not in stopwords:
        final+= seg+' '
In [34]: print(final)
黄旭华/1926/年/3/月/12/日出/生于/广/东省/汕尾市/原籍/广/东省/揭阳市/1949/年/毕业/于/上海交通大学/历任/北京/海军/核潜艇/研究室/副/总工程师/中船
重工集团公司/核潜艇/总体/研究/设计所/研究员/名誉/所长/1994/年/当选/为/中国工程院院士/
```

作业的意义：

- 你可以处理比较复杂的文本啦
- 你开始尝试接触和理解，一些具有文化内涵的科技文献资源

第一讲 课程导言与分词

3. 完成课后作业（001-004，4份代码的运行）

```
In [1]: # 1. 第一步, 我们把文本人工提取出来
In [2]: # 落实“企业管理年”主题, 加强QHSE三体系建设, 通过自动化、数字化、智能化升级改造加快新一代信息技术与企业生产经营融合, 打造精益制造能力, 提升精
In [3]: # 第二步, 安装需要的python库, 也就是工具包
# 我们的需求是: 1) 使用jieba分词, 对文本进行分词; 2) 统计给定词汇的频次, 比如: 自动化, 数字化, 安全。
In [4]: import jieba
from collections import Counter
In [5]: # 文本
text = """
落实“企业管理年”主题, 加强QHSE三体系建设,
通过自动化、数字化、智能化升级改造加快新一代信息技术与企业生产经营融合,
打造精益制造能力, 提升精细化管理水平, 助力公司从“制造”升级为“智造”,
从而提高经营效率和效益;通过集团一体化智慧管理平台建设与运营,
丰富企业供应链管理、生产工艺控制等管理工具, 不断增强生产经营过程数据获取与分析能力,
强化全过程一体化管理, 提高自动化、数字化、智能化的供应链管理能力,
为体系安全稳定运行与管理水平提升保驾护航, 整力打造安全智能化工厂;
打造助剂互联网技术合作和商务合作平台, 构建具有国际竞争力的供应链体系。
"""
In [6]: # 1. 分词处理
words = jieba.lcut(text)

Building prefix dict from the default dictionary ...
Loading model from cache C:\Users\admin\AppData\Local\Temp\jieba.cache
Loading model cost 0.746 seconds.
Prefix dict has been built successfully.

In [7]: words
Out[7]: ['\n', '落实', '、', '企业', '管理', '年', '、', '主题', '、', 'QHSE', '三', '体系', '建设', '\n', '通过', '自动化', '、', '']
In [8]: # 2. 定义要统计的特殊词汇
target_words = ['数字化', '智能化', '安全']

In [9]: # 统计词频
word_counts = Counter(words)

In [10]: # 输出特定词汇的词频统计结果
print("特定词汇词频统计结果:")
for word in target_words:
    print(f"\t{word}: {word_counts[word]} 次")
特定词汇词频统计结果:
'数字化': 2次
'智能化': 3次
'安全': 2次

In [11]: # 输出所有词汇的词频(按频率降序)
print("\n所有词汇词频统计(前20个):")
for word, count in word_counts.most_common(20):
    print(f"\t{word}: {count} 次")

所有词汇词频统计(前20个):
': 13次
'': 9次
'管理': 5次
'、': 5次
'与': 4次
'': 3次
'企业': 3次
'': 3次
'体系': 3次
'智能化': 3次
'经营': 3次
'打造': 3次
'能力': 3次
'供应链': 3次
'建设': 2次
'通过': 2次
'自动化': 2次
'数字化': 2次
'升级': 2次
'生产': 2次
```

第一讲 课程导言与分词

3. 完成课后作业（001-004，4份代码的运行）。

提取到的实体和专业术语：

```
```json
{
 "理论": [
 "肿瘤免疫微环境",
 "免疫编辑理论"
],
 "方法": [
 "单细胞RNA测序",
 "细胞亚群聚类",
 "轨迹分析",
 "pseudotime推断",
 "细胞间通讯网络构建"
],
 "工具": [
 "Seurat",
 "Monocle3",
 "CellChat"
],
 "专业术语": [
 "T细胞耗竭",
 "scRNA-seq",
 "非小细胞肺癌",
 "免疫抑制信号通路",
 "PD-1/PD-L1",
 "TGF-β 路径",
 "个体化免疫治疗"
]
}
```

```

第一讲 课程导言与分词

4. 谈一谈在营销学科/领域，文本、文本分词以及实体的内涵。例如：客户关系管理中，文本分析的价值。（仅营销）

阅读这篇关于学术论文研究方法自动分类的论文，最直观的感受是其对“全文价值”的深度挖掘与实践突破。在以往的相关研究中，受限于文献获取条件和技术成本，大多依赖摘要、标题等短文本信息开展分类，却忽略了全文中更丰富的研究方法上下文——这篇论文恰恰抓住了这一核心痛点，以 820 篇图书情报领域的论文全文为基础，通过专家标注构建语料库，为分类任务提供了更扎实的数据源，这种“回归文本本身”的研究思路，让分类结果更具可信度。

论文在技术设计上的严谨性也令人印象深刻。面对学术论文可能存在多种研究方法的现实情况，其采用多标签分类的思路，兼顾问题转换法与算法自适应法，构建了 7 种不同的分类模型进行对比，既考虑了标签间的关联性，又覆盖了不同底层分类器的特性。尤其是朴素贝叶斯算法在分类器链策略中取得 0.705 的 F1 值，证明了传统机器学习算法在特定场景下依然具备强大的适配性，而实验法、计量法因特征表征能力强而获得更高分类准确率的结果，也揭示了“方法本身的特性”与“文本特征提取”之间的密切关联，为后续研究提供了明确的优化方向。

更值得深思的是，论文不仅关注技术层面的优化，更兼顾了研究的实际应用价值。人工分类学术论文研究方法存在成本高、主观性强的弊端，而该研究构建的自动分类模型，既降低了人工依赖，又能为科研人员选择研究方法、分析学科方法演变趋势提供数据支撑，真正实现了技术服务学术研究的初衷。同时，论文也坦诚指出了研究的局限性，如训练集规模对泛化效果的影响、样本不均衡的问题等，这种客观的自我审视，让研究更具延续性和拓展空间。

整体而言，这篇论文以清晰的逻辑、扎实的实验和务实的价值导向，为文本分类在学术研究领域的应用提供了优秀范例。它让我意识到，学术研究中“看似基础的调整”（如从摘要到全文的数据源转换），往往能带来突破性的成果，而技术创新的核心，始终是围绕“解决实际问题”展开的精准发力。