

用户数据采集与关联分析

(结课作业)



吴志祥

18205185639

1030624832@qq.com

01 文本数据分析



吴志祥


18205185639

cnwzx2012@njtech.edu.cn


第四

经济与

```
1 from snownlp import SnowNLP
2 import matplotlib.pyplot as plt
3 import numpy as np
4
5 # ----- 1. 准备待分析文本 -----
6 # 读取新能源汽车用户评论文本（包含积极、消极、中性评价）
7 text = """
8 这款新能源汽车的续航真的超出预期，充一次电跑500公里完全没问题，太满意了！
9 内饰做工很精致，智能驾驶功能也很好用，操作简单流畅，推荐大家购买。
10 价格有点贵，比同级别燃油车贵了3倍多，性价比一般。
11 驾驶有点稳，试驾时感觉到油门偏长，安全性让人担心。
12 空间表现中规中矩，后排三个成年人刚好，不算拥挤也不算宽敞。
13 售后服务态度很好，有问题响应很快，维修保养费用也合理。
14 极限驾驶严格，实测只能到350公里左右，和宣传的距离太大了。
15 外观设计很时尚，回头率很高，身边朋友都问是什么车型。
16 充电速度有点慢，快充需要1.5小时才能充满，不太方便长途出行。
17 整体来说还不错，虽然有小缺点，但在新能源车里算是表现优秀的了。
18 """
19
20 # ----- 2. 文本分割与情感计算 -----
21 # 按句号分割文本（基于中文标点）
22 sentences = [s.strip() for s in text.replace("\n", "\n").split(".") if s.strip()]
23
24 # 逐句计算情感得分(0~1) 并分类
25 emotion_scores = []
26 positive_sentences = [] # 积极 (得分>0.6)
27 neutral_sentences = [] # 中性 (0.4 < 得分 < 0.6)
28 negative_sentences = [] # 消极 (得分<0.4)
29
30 for sent in sentences:
31     score = SnowNLP(sent).sentiments
32     emotion_scores.append(score)
33     if score >= 0.6:
34         positive_sentences.append(sent)
35     elif score <= 0.4:
36         negative_sentences.append(sent)
37     else:
38         neutral_sentences.append(sent)
39
40 # 统计各类情感占比
41 total = len(sentences)
42 pos_ratio = len(positive_sentences) / total * 100
43 neu_ratio = len(neutral_sentences) / total * 100
44 neg_ratio = len(negative_sentences) / total * 100
45
46 # ----- 3. 生成可视化图表 -----
47 plt.rcParams['font.sans-serif'] = ['SimHei'] # 解决中文显示问题
48 plt.rcParams['axes.unicode_minus'] = False # 解决负号显示问题
49
50 # 创建2x1子图 (情感分布直方图 + 情感占比饼图)
51 fig, (ax1, ax2) = plt.subplots(rows=2, ncols=1, figsize=(12, 10))
52
53 # 子图1：情感分布直方图
54 ax1.hist(emotion_scores, bins=10, color="#f777b4", alpha=0.7, edgecolor='black')
55 ax1.axvline(x=0.4, color='orange', linestyle='--', linewidth=2, label='消极-中性分界 (0.4)')
56 ax1.axvline(x=0.6, color='red', linestyle='--', linewidth=2, label='中性-积极分界 (0.6)')
57 ax1.set_xlabel('情感得分 (0=消极, 1=积极)', fontsize=12)
58 ax1.set_ylabel('句子数量', fontsize=12)
59 ax1.set_title('新能源汽车用户评论情感得分分布', fontsize=14, fontweight='bold')
60 ax1.legend()
61 ax1.grid(alpha=0.3)
62
63 # 子图2：情感占比饼图
64 labels = ['积极评价', '中性评价', '消极评价']
65 sizes = [pos_ratio, neu_ratio, neg_ratio]
66 colors = ['#2ca02c', '#ff7f0e', '#d62728']
67 explode = (0.05, 0, 0) # 突出积极评价
68
69 wedges, texts, autotexts = ax2.pie(sizes, explode=explode, labels=labels, colors=colors, autopct='%1.1f%%',
70                                     shadow=True, startangle=90, textprops={'fontsize': 11})
71
72 ax2.set_title('新能源汽车用户评论情感占比', fontsize=14, fontweight='bold')
73
74 # 调整子图间距
75 plt.tight_layout()
76
77 # 保存图片 (高清格式)
78 plt.savefig('img/emotion_analysis_result.png', dpi=300, bbox_inches='tight')
79 plt.show()
80
81 # ----- 4. 输出分析结果 -----
82 print("==> 情感分析结果汇报 ==>")
83 print(f"总评论句子数: {total} 句")
84 print(f"积极评价: {len(positive_sentences)} 句 ({pos_ratio:.1f}%)")
85 print(f"中性评价: {len(neutral_sentences)} 句 ({neu_ratio:.1f}%)")
86 print(f"消极评价: {len(negative_sentences)} 句 ({neg_ratio:.1f}%)")
87
88 print("==> 积极评价示例 ==>")
89 print("积极评价示例: ", positive_sentences[0] if positive_sentences else "无")
90 print("消极评价示例: ", negative_sentences[0] if negative_sentences else "无")
```



新能源汽车用户评论情感占比



第四讲 情感分析

2. 完成sentiment_analysis 4份代码。做截图，并简要做

alysis_4,
T。

In [8]: # 在anaconda prompt里面运行

```
pip install snowpl
pip install -U textblob
python -m textblob.download_corpora
```

英文

In [8]: # 美文测试textblob NLP处理

Features

- Noun phrase extraction
- Part-of-speech tagging
- Sentiment analysis
- Classification (Naive Bayes, Decision Tree)
- Language translation and detection powered by Google Translate
- Tokenization (splitting text into words and sentences)
- Word and phrase frequencies
- Parsing
- n-grams
- Word inflection (pluralization and singularization) and lemmatization
- Spelling correction
- Add new models or languages through extensions
- WordNet integration

In [8]: text = "I am happy today. I feel sad today."

In [8]: from textblob import TextBlob

In [8]: blob = TextBlob(text)

In [8]: blob

In [8]: # 原封不动的打印出来了?
实际上已经把文本分成了句子了，看一看

In [8]: blob.sentences

In [8]: blob.sentences[0].sentiment

In [8]: # 上面的结果是什么意思?
情感极性的S, 介于-1.0, -1代表完全负面, 1代表完全正面。
我表达的是积极语义, 那么这个结果是好的

In [8]: blob.sentences[1].sentiment

In [8]: # 测段文本的情感呢?
blob.sentiment

In [8]: # 你可能会觉得没有道理, 泰一句“离我”, 合并起来之后会得到正面结果呢?
其实不同领域的词, 在数值上是有区别的, 我们应该找到比“离我”更为负面的词汇, 而且这也将合理, 那么这个“天上一脚, 地下一脚”矛盾地描述自己

中文

In [8]: # 中文分析, 用的是SnowNLP

Features

- 中文分词 (Character-Based Generative Model)
- 词性标注 (TnT 3-gram 随机)
- 情感分析 (现在训练数据主要是卖东西时的评价, 所以对其他的一些可能效果不是很好, 待解决)
- 文本分类 (Naive Bayes)
- 转换成拼音 (Trie树实现的最大匹配)
- 繁体转简 (Trie树实现的最大匹配)
- 当取文本关键词 (TextRank算法)
- 当取文本摘要 (TextRank算法)
- tf, idf
- Tokenization (分割成句子)
- 文本相似 (BM25)
- 支持python3 (感谢erning)

In [8]: text_cn = u"我今天很快乐, 我今天很愤怒."

In [8]: # 注意在引号前面我们加了一个字母u, 它很重要, 因为它提示Python, “这一段我们输入的文本编码格式是unicode, 别搞错了哦”. 关于文本编码格式的细节, 有

In [8]: from snownlp import SnowNLP

In [8]: senti_cn = SnowNLP(text_cn)

In [8]: # 看看snownlp的分句能力
for sentence in senti_cn.sentences:

In [8]: print(sentence)

In [8]: senti_cn_1 = SnowNLP(senti_cn.sentences[0])

In [8]: # 一个简单的问句, 英文是senti_cn.sentiments, 中文是x.sentiments, 多了一个s
另外, 在句首上的英文的也略有不同, 比如直接用语句senti_cn.sentences[0], sentiments是会报错的
senti_cn_1.sentiments

In [8]: senti_cn_2 = SnowNLP(senti_cn.sentences[1])

In [8]: senti_cn_2.sentiments

这里你肯定发现了问题——“愤怒”这个词表达了如此强烈的负面情感, 为何得分依然靠前?

这是因为SnowNLP和textblob的分句方法不同。SnowNLP的情感分析取值, 表达的是“这句话代表正面情感的概率”。也就是说, 对“我今天很愤怒”一句, SnowNLP认为, 它表达正面情感的概率很低很低。


这样解释就是ok了

In [8]: senti_cn.sentiments

In [8]: # 些个句子, 我似乎有问题

第四讲 情感分析

2. 完成sentiment_analysis_4, 4份代码。做截图，并简要做结分析。



第四讲 情感分析

2. 完成sentiment_analysis

4份代码。做截图，并简要做

In [1]: # 在deepseek api平台申请API, 拿到API-key; 然后交一点钱, 很便宜的。

In [2]: # https://platform.deepseek.com/transactions

以下是一段采用大语言模型处理“心理-身体”病痛文本，细粒度情感/感受/症状实体与实体关系提取的工作

```
import requests
# DeepSeek API 客户端
url = "https://api.deepseek.com/v1/chat/completions"
# 患者的API密钥
API_KEY = "3a-4ef9002c1e4a3f484c3ff2af4d53a10" # 直接复制过来
# 请求头, 包含 API 密钥和内容类型
headers = {
    "Authorization": f"Bearer {API_KEY}",
    "Content-Type": "application/json"
}

# 患者描述文本
text = (
    "我有差不多一星期感觉到生活失去了重心, 开始出现失眠、头痛和疲乏无力的症状。"
    "我感觉头部变得非常敏感, 连衣服的触感都像针扎一样疼痛。"
    "我常常感到心慌、胸闷, 胸部沉甸甸地像压了一块石头。"
    "对光线和声音变得极度敏感, 电话铃声都会让我惊恐。"
    "多次出现睡眠障碍, 经常醒来并感到非常困倦和疲惫。"
    "我变得非常敏感, 想要与人交流, 但又把自己关在屋里, 拉紧窗帘, 感觉生活毫无意义。"
)

# 构建提示语, 要求模型提取细粒度情感实体
prompt = (
    "请从以下患者描述中提取出具体的部位、症状以及对应的情感状态, "
    "并用{'部位': '部位', '症状': '症状', '情感': '情感'}的格式返回。"
    "实体: ([部位], ... , [症状], ... , [情感], ... )\n"
    "患者描述: (text)"
)

# 提交请求, 包含模型参数和提示词
data = {
    "model": "deeplearn-chat",
    "messages": [
        {"role": "user", "content": prompt}
    ],
    "temperature": 0.3
}

# 发送 POST 请求
response = requests.post(url, headers=headers, data=json.dumps(data))

# 检查响应状态码
if response.status_code == 200:
    # 解析 JSON 响应
    result = response.json()
    generated_text = result['choices'][0]['message']['content']
    print("细粒度情感实体抽取结果:")
    print(generated_text)
else:
    # 处理错误响应
    print(f"错误信息: {response.status_code}")
    print(f"错误信息: {response.text}")

except requests.exceptions.RequestException as e:
    # 处理网络连接异常
    print(f"网络请求失败: ({e})")
except json.JSONDecodeError as e:
    # 处理 JSON 解析失败
    print(f"JSON 解析失败: ({e})")
except Exception as e:
    # 处理其他异常
    print(f"发生未知错误: ({e})")
```

提问:

1. 请问你要得大语言模型在识别患者的身体、心理、情感的工作中, 表现如何?

2. 除了健康领域的感情世界理解与识别, 你还能想到哪些其他重要的领域, 可以开展类似的工作呢?

第四讲 情感分析

2. 完成sentiment_analysis
4份代码。做截图，并简要做文字作品的情感轨迹

1. 读取文本，提取情感词，根据语境，对文件进行标注，并且对句子进行排序。
2. 读取大段数据，提取每一段的首句，每句的话的语境，根据语境，读出情感。
3. 分别读取每段话，第一个句子的语境，根据语境，读出情感的极性。
4. 对每段话，根据语境，读出情感的极性，根据语境，读出情感的强度。
5. 对每段话，根据语境，读出情感的极性，根据语境，读出情感的强度。

```
In [1]: import re  
with open('HW1.txt', 'r', encoding='utf-8') as f:  
    text = f.read()  
    # 将文本，转化为字典形式  
    sentences = [text[i:i+100] for i in range(0, len(text), 100)]  
    for sentence in sentences:  
        print(sentence)  
        # 将每段话，转化为字典形式  
        numbered_sentences = {i: sentence[i:i+100] for i in range(0, len(sentence), 100)}  
        numbered_sentences = numbered_sentences.items()  
        for num, sent in numbered_sentences:  
            print(num, sent)
```

nt_analysis_4,
结分析。

